

Vaja 1 – Metoda nelinearnih najmanjših kvadratov

Ime in priimek: **Gašper Leskovec**

Predmet: Inteligentni sistemi za podporo odločanju

Datum: 27. julij 2026

1 Uvod

V tej nalogi smo obravnavali problem določanja položaja izgubljenega mobilnega telefona na podlagi meritev razdalj do treh baznih postaj. Ker so meritve obremenjene s šumom, problema ni smiselno obravnavati kot eksaktno reševanje sistema enačb – tri šumne krožnice se v splošnem ne sekajo v eni točki. Namesto tega problem zastavimo kot *optimizacijski problem*: iščemo točko, ki se izmerjenim razdaljam “najbolje prilega” v smislu najmanjše vrednosti izbrane kriterijske funkcije. Za rešitev smo uporabili metodo nelinearnih najmanjših kvadratov, natančneje Levenberg–Marquardtovo (LM) metodo.

Poleg osnovne lokalizacije smo v nalogi obravnavali tri metodološka vprašanja, ki so ključna za pravilno statistično interpretacijo rezultata:

1. kako v kriterijsko funkcijo vključiti *varianco meritev* posameznih postaj (uteženi najmanjši kvadrati, WLS),
2. kako pravilno izvesti LM iteracijo z logiko *sprejmi/zavrni* (accept/reject), ki koraka ne sprejme brezpogojno,
3. kako pravilno oceniti *varianco ocene pozicije* – z Monte Carlo ponovitvami neodvisnih eksperimentov, ne z varianco optimizacijske poti.

2 Opis naloge

Tri bazne postaje so postavljene v ravnini na znanih koordinatah:

- Bazna postaja 1: (1, 1)
- Bazna postaja 2: (10, 5)
- Bazna postaja 3: (2, 4)

Vsaka bazna postaja ob klicu funkcije `ping_stolp_1`, `ping_stolp_2` oziroma `ping_stolp_3` vrne eno šumno meritev razdalje do telefona; vsak klic vrne drugačno vrednost.

Naloga je bila sestavljena iz treh delov:

1. določitev položaja telefona pri $N = 100$ meritvah na postajo, v neuteženi in uteženi izvedbi,
2. Monte Carlo analiza vpliva števila meritev $N \in \{1, 5, 10, 50, 100\}$ na varianco končne ocene in na konvergenco,
3. primerjava uteženega in neuteženega pristopa pri $N = 100$.

Naloga je rešena izključno z osnovnim MATLAB-om, brez uporabe toolboxov (tudi krožnice na slikah so narisane ročno s parametrizacijo $(x_c + r \cos \theta, y_c + r \sin \theta)$).

3 Matematični model

3.1 Optimizacijski problem in kriterijska funkcija

Naj bo neznani položaj telefona podan z vektorjem

$$\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}.$$

Če bi bile meritve točne, bi za vsako postajo veljalo $(x - x_i)^2 + (y - y_i)^2 = d_i^2$. Ker so meritve šumne, enačbe niso izpolnjene eksaktno; za vsako bazno postajo zato definiramo *rezidual* (ostanek), ki pove, kako daleč je točka (x, y) od izpolnitve i -te enačbe:

$$F_i(x, y) = (x - x_i)^2 + (y - y_i)^2 - d_i^2,$$

kjer sta (x_i, y_i) koordinati i -te bazne postaje, d_i pa (povprečena) izmerjena razdalja do telefona. Celoten rezidualni vektor je

$$\mathbf{F}(x, y) = \begin{bmatrix} (x - x_1)^2 + (y - y_1)^2 - d_1^2 \\ (x - x_2)^2 + (y - y_2)^2 - d_2^2 \\ (x - x_3)^2 + (y - y_3)^2 - d_3^2 \end{bmatrix}.$$

Optimizacijski problem se glasi: poišči (x, y) , ki minimizira *kriterijsko funkcijo*

$$J(x, y) = \mathbf{F}^T \mathbf{W} \mathbf{F}, \quad (1)$$

kjer je $\mathbf{W}$ diagonalna matrika uteži. Kriterijska funkcija je torej utežena vsota kvadratov rezidualov: vsaka postaja prispeva svoj kvadrirani rezidual, pomnožen s svojo utežjo. V posebnem primeru $\mathbf{W} = \mathbf{I}$ dobimo običajne (neutežene) najmanjše kvadrate $J = \|\mathbf{F}\|^2$.

3.2 Uteženi najmanjši kvadrati in varianca meritev

Vse tri postaje niso enako zanesljive: šum meritev ima pri vsaki postaji drugačno velikost. Če iz N surovih meritev $d_i^{(1)}, \dots, d_i^{(N)}$ za vsako postajo poleg povprečja

$$\bar{d}_i = \frac{1}{N} \sum_{k=1}^N d_i^{(k)}$$

ocenimo še vzorčno varianco

$$\sigma_i^2 = \frac{1}{N-1} \sum_{k=1}^N \left(d_i^{(k)} - \bar{d}_i \right)^2,$$

lahko to informacijo vgradimo v kriterij (1) z izbiro

$$\mathbf{W} = \text{diag} \left(\frac{1}{\sigma_1^2}, \frac{1}{\sigma_2^2}, \frac{1}{\sigma_3^2} \right). \quad (2)$$

Zakaj je ta izbira smiselna? Intuitivno: rezidual postaje z velikim raztrosom meritev je že zaradi šuma pogosto velik, čeprav je točka (x, y) pravilna – taki postaji zato ne smemo slepo verjeti in njen prispevek h kriteriju pomnožimo z majhno utežjo $1/\sigma_i^2$. Nasprotno postaja z majhno varianco meri natančno, zato njen rezidual nosi več informacije in dobi veliko utež. Formalno ta izbira izhaja iz metode največjega verjetja: če so pogreški meritev neodvisni in normalno porazdeljeni z različnimi variancami (heteroskedastičen šum), je ocena z največjim verjetjem ravno rešitev uteženih najmanjših kvadratov z utežmi, obratno sorazmernimi z variancami. Uteženje s $1/\sigma_i^2$ poleg tega poskrbi, da so členi kriterija brezdimenzijski in medsebojno primerljivi – vsak rezidual je normiran s “tipično” velikostjo svojega šuma.

3.3 Levenberg–Marquardtova metoda z logiko sprejmi/zavrni

Kriterij (1) je nelinearna funkcija parametrov, zato ga minimiziramo iterativno. Jacobijeva matrika rezidualov je

$$\mathbf{J}(x, y) = \begin{bmatrix} 2(x - x_1) & 2(y - y_1) \\ 2(x - x_2) & 2(y - y_2) \\ 2(x - x_3) & 2(y - y_3) \end{bmatrix},$$

kandidat za korak v k -ti iteraciji pa je rešitev linearnega sistema

$$\Delta = (\mathbf{J}^T \mathbf{W} \mathbf{J} + \lambda \mathbf{I})^{-1} (-\mathbf{J}^T \mathbf{W} \mathbf{F}). \quad (3)$$

Parameter dušenja λ interpolira med Gauss–Newtonovo metodo (majhen λ , dolgi in “pogumni” koraki) in gradientnim spustom z majhnim korakom (velik λ , kratki in previdni koraki).

Ključno je, da izračunani korak Δ obravnavamo zgolj kot *kandidata*, ne kot dokončno posodobitev. Enačba (3) namreč temelji na linearizaciji rezidualov okoli trenutne točke; če je korak predolg, linearizacija zunaj njene okolice ne velja več in kriterij se v novi točki lahko celo *poslabša*. Metoda, ki vsak korak sprejme brezpogojno, lahko zato skače po prostoru parametrov in v neugodnih primerih divergira – prilagajanje λ šele *po* že sprejetem slabem koraku škode ne prepreči. Pravilna LM iteracija zato deluje po logiki *sprejmi/zavrni*:

1. izračunaj kandidata $\mathbf{x}_{\text{new}} = \mathbf{x}_k + \Delta$ in vrednost kriterija $J(\mathbf{x}_{\text{new}})$;
2. če je $J(\mathbf{x}_{\text{new}}) < J(\mathbf{x}_k)$: korak **sprejmi** ($\mathbf{x}_{k+1} = \mathbf{x}_{\text{new}}$), zmanjšaj $\lambda \leftarrow \lambda/10$ (linearizaciji lahko bolj zaupamo) in preveri konvergenco ($\|\Delta\| < 10^{-6}$);
3. sicer: korak **zavrni** ($\mathbf{x}_{k+1} = \mathbf{x}_k$, položaj se ne spremeni), povečaj $\lambda \leftarrow 10\lambda$ in iz iste točke poskusi znova s krajšim, bolj dušenim korakom;
4. varovalka: če λ preseže 10^{10} , se iteracija prekine z opozorilom (preprečitev neskončne zanke zavračanj).

Pomembno je razumeti, kaj ta logika garantira in česa ne. *Garantira* monotono padanje kriterija J po sprejetih korakih: vrednost uteženega kvadrata rezidualov se z vsakim sprejetim korakom strogo zmanjša, zato metoda ne more “pobegniti” od že dosežene kakovosti rešitve. *Ne garantira* pa ravne ali monotone poti samih parametrov: sprejeti korak lahko posamezno koordinato začasno odmakne od končne rešitve, če se kriterij pri tem vseeno zmanjša. Na to se vrnemo pri interpretaciji konvergenčnega grafa v razdelku 5.2.

3.4 Varianca poti proti Monte Carlo varianci ocene

Zadnje metodološko vprašanje je, kaj sploh pomeni “varianca pozicije”. Varianca točk $\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_K$ vzdolž *ene* optimizacijske poti meri le, kako razpotegnjena je pot od začetnega približka do rešitve, in je odvisna od izbire začetne točke ter dinamike algoritma, ne pa od šuma v podatkih. O negotovosti končne ocene torej ne pove ničesar.

Prava mera negotovosti je *varianca cenilke*: kako se končna ocena razlikuje med neodvisnimi ponovitvami celotnega eksperimenta. Ocenimo jo z Monte Carlo (MC) pristopom: eksperiment (zajem N svežih meritev na postajo, povprečenje, optimizacija) neodvisno ponovimo M -krat in izračunamo varianco M končnih ocen

$$\widehat{\text{Var}}(\hat{x}) = \frac{1}{M-1} \sum_{m=1}^M \left(\hat{x}^{(m)} - \bar{\hat{x}} \right)^2,$$

in analogno za $\hat{y}$. Ta količina neposredno odgovarja na vprašanje: “Če bi eksperiment ponovili, koliko drugačen rezultat bi dobili?” – kar je natanko definicija negotovosti ocene.

Teorija pri tem napove konkretno odvisnost od N . Povprečje N neodvisnih meritev z varianco σ^2 ima varianco

$$\text{Var}(\bar{d}) = \frac{\sigma^2}{N},$$

in ker je končna ocena pozicije (lokalno) gladka funkcija povprečenih razdalj, se ta faktor $1/N$ v prvem redu prenese tudi na varianco ocene pozicije:

$$\text{Var}(\hat{x}) \propto \frac{1}{N}, \quad \text{Var}(\hat{y}) \propto \frac{1}{N}. \quad (4)$$

To napoved v razdelku 6 kvantitativno preverimo.

4 Metodologija

Pri implementaciji smo uporabili naslednje nastavitve:

- začetna ocena položaja telefona: $(0, 0)$,
- začetni parameter dušenja: $\lambda_0 = 0.001$,
- toleranca za konvergenco: $\|\Delta\| < 10^{-6}$,
- maksimalno število iteracij: 1000; varovalka $\lambda \leq 10^{10}$,
- seme generatorja naključnih števil: `rng(42)` (ponovljivost).

Eksperimenti so organizirani v tri dele:

1. **Glavna lokalizacija** ($N = 100$): surove meritve vseh treh postaj shranimo v vektorje, izračunamo povprečja $\bar{d}_i$ in vzorčne variance σ_i^2 , nato izvedemo LM optimizacijo v dveh variantah – neuteženo ($\mathbf{W} = \mathbf{I}$) in uteženo ($\mathbf{W}$ po enačbi (2)).
2. **Monte Carlo analiza vpliva N** : za vsak $N \in \{1, 5, 10, 50, 100\}$ izvedemo $M = 100$ neodvisnih ponovitev eksperimenta in izračunamo povprečno oceno, MC varianco končnih ocen ter povprečno število iteracij. V tem delu uporabimo neuteženo varianto za konsistentnost čez vse N : pri $N = 1$ vzorčne variance meritev ni mogoče oceniti, zato uteži $1/\sigma_i^2$ ne bi bile definirane.
3. **Primerjava WLS in neuteženega pristopa** ($N = 100$, $M = 100$): v vsaki ponovitvi na *istih* podatkih izračunamo neuteženo in uteženo oceno, nato primerjamo raztros obeh oblakov končnih ocen.

5 Rezultati

5.1 Statistika meritev po postajah

Tabela 1 prikazuje povprečje, varianco in standardni odklon $N = 100$ surovih meritev za vsako bazno postajo.

Bazna postaja	Povprečje $\bar{d}_i$	Varianca σ_i^2	Std σ_i
1	4.3373	0.0107	0.1034
2	5.5922	0.1013	0.3183
3	3.7254	0.0027	0.0515

Tabela 1: Statistika meritev razdalj po baznih postajah pri $N = 100$.


Postaje se po zanesljivosti izrazito razlikujejo: postaja 2 ima varianco 0.1013, kar je približno 37-krat več od postaje 3 (0.0027) in približno 9-krat več od postaje 1 (0.0107). V uteženem kriteriju zato postaja 3 dobi daleč največjo utež, postaja 2 pa najmanjšo – prav takšna razmerja zanesljivosti so razlog, da je uteženje iz razdelka 3.2 smiselno.

5.2 Glavna lokalizacija za $N = 100$

Obe varianti optimizacije sta konvergirali h koordinatam v neposredni bližini točke (5.2, 2.1):


- neuteženo ($\mathbf{W} = \mathbf{I}$): $(x, y) = (5.2050, 2.1111)$, 7 iteracij,
- uteženo (WLS): $(x, y) = (5.2009, 2.0948)$, 13 iteracij.

Na sliki 1 je prikazana konvergenca parametrov x in y po sprejetih korakih utežene optimizacije. Opazimo, da koordinata y v prvih korakih najprej zavije v negativno smer in se šele nato obrne proti končni vrednosti. To *ni* napaka metode: kot smo pojasnili v razdelku 3.3, logika sprejmi/zavrni garantira monotono padanje kriterija J , ne pa monotonega gibanja posameznih koordinat. Prikazani začetni koraki so bili sprejeti, ker so vrednost J dejansko zmanjšali – pot parametrov je pri tem lahko ovinkasta.



Slika 1: Konvergenca parametrov x in y po sprejetih korakih utežene LM optimizacije pri $N = 100$.

Slika 2 prikazuje geometrijo problema: bazne postaje, ročno narisane krožnice z radiji $\bar{d}_i$, pot optimizacije ter obe končni oceni. Krožnice se zaradi šuma ne sekajo v eni točki, obe oceni pa ležita v območju njihovega “skoraj-presečišča”.



Slika 2: Geometrijski prikaz lokalizacije telefona za $N = 100$ z ročno narisanimi krožnicami ter neuteženo in uteženo oceno.

5.3 Monte Carlo analiza vpliva števila meritev


Tabela 2 povzema rezultate $M = 100$ neodvisnih ponovitev za vsak N .

Število meritev (N)	Povpr. x	Povpr. y	Povpr. št. iteracij	MC Var(x)	MC Var(y)
1	5.1911	2.0716	9.6	0.010771	0.084259
5	5.1922	2.0809	8.5	0.002071	0.016052
10	5.1969	2.0986	8.2	0.000981	0.007555
50	5.1996	2.1012	7.8	0.000198	0.001808
100	5.1994	2.0990	7.6	0.000104	0.000779

Tabela 2: Monte Carlo rezultati za različne vrednosti števila meritev N ($M = 100$ ponovitev na vsak N , neutežena varianta).


Povprečne ocene so za vse N praktično enake (okoli (5.19, 2.10)) – povprečenje čez M ponovitev odstrani naključni raztros posamezne ponovitve. Bistvena razlika med vrednostmi N je v MC varianci končnih ocen, ki z naraščajočim N strmo pada: $\text{Var}(\hat{x})$ od 0.010771 pri $N = 1$ do 0.000104 pri $N = 100$, $\text{Var}(\hat{y})$ od 0.084259 do 0.000779. Povprečno število iteracij rahlo pada z N (od 9.6 pri $N = 1$ do 7.6 pri $N = 100$): manj šumni podatki dajo bolj konsistentne rezidualne in nekoliko lažjo optimizacijo, konvergenca pa je hitra v vseh primerih.

Slika 3 raztros prikaže neposredno: vsak oblak točk so končne ocene 100 neodvisnih ponovitev pri danem N . Krčenje oblakov z naraščajočim N je vizualni prikaz padanja variance iz tabele 2.




Slika 3: Oblaki končnih Monte Carlo ocen za različne N . Z večanjem N se raztros ocen vidno krči.

Sliki 4 in 5 prikazujeta MC varianco in povprečno število iteracij v odvisnosti od N .



Slika 4: Monte Carlo varianca končnih ocen $\hat{x}$ in $\hat{y}$ v odvisnosti od števila meritev N . Varianca z naraščajočim N pada v skladu z zakonom $1/N$.



Slika 5: Povprečno število iteracij do konvergence glede na število meritev N .


5.4 Primerjava uteženega in neuteženega pristopa

Tabela 3 povzema primerjavo obeh pristopov čez $M = 100$ neodvisnih ponovitev pri $N = 100$, pri čemer sta v vsaki ponovitvi obe varianti uporabili iste podatke.

Varianta	Povpr. x	Povpr. y	$\text{Var}(x)$	$\text{Var}(y)$	$\text{Std}(x)$	$\text{Std}(y)$
Neuteženo	5.1971	2.0927	0.000112	0.000863	0.0106	0.0294
Uteženo (WLS)	5.1983	2.0981	0.000054	0.000213	0.0074	0.0146

Tabela 3: Primerjava neuteženih in uteženih (WLS) najmanjših kvadratov čez $M = 100$ ponovitev pri $N = 100$.

Slika 6 prikazuje oba oblaka končnih ocen. Uteženi oblak je vidno bolj zgoščen od neuteženega, obe povprečji pa sovpadata.



Slika 6: Oblaka končnih ocen neutežene in utežene optimizacije ($M = 100$, $N = 100$). Uteženje raztros ocen občutno zmanjša.

6 Analiza in interpretacija rezultatov

6.1 Kvantitativna potrditev zakona $1/N$

Enačba (4) napove, da mora MC varianca ocene pasti obratno sorazmerno s številom meritev: pri 100-krat večjem N pričakujemo 100-krat manjšo varianco. Razmerji izmerjenih varianc med skrajnima vrednostma N znašata

$$\frac{\text{Var}(\hat{x})|_{N=1}}{\text{Var}(\hat{x})|_{N=100}} = \frac{0.010771}{0.000104} \approx 104, \quad \frac{\text{Var}(\hat{y})|_{N=1}}{\text{Var}(\hat{y})|_{N=100}} = \frac{0.084259}{0.000779} \approx 108,$$

kar se zelo dobro ujema s teoretično napovedjo $N = 100$. Razlog je preprost: povprečje N neodvisnih meritev ima varianco σ^2/N , končna ocena pozicije pa je gladka funkcija teh povprečij, zato podeduje isti faktor $1/N$. Manjši odstopanji od točne vrednosti 100 (≈ 104 oziroma ≈ 108) sta pričakovana posledica končnega števila ponovitev ($M = 100$) – tudi sama MC ocena variance je namreč naključna količina s svojim raztrosom. Enak trend potrjujejo vmesne vrednosti N v tabeli 2 in krčenje oblakov na sliki 3.

6.2 Učinek uteževanja z varianco meritev

Primerjava v tabeli 3 pokaže, da uteženje po enačbi (2) raztros končnih ocen občutno zmanjša: varianca $\hat{x}$ pade z 0.000112 na 0.000054 (faktor ≈ 2.1), varianca $\hat{y}$ z 0.000863 na 0.000213 (faktor ≈ 4.1); standardna odklona se zmanjšata s 0.0106 na 0.0074 oziroma z 0.0294 na 0.0146. Povprečji obeh pristopov sovpadata ((5.1971, 2.0927) proti (5.1983, 2.0981)), kar pomeni, da uteženje ne vnaša pristranskosti, temveč zgolj zmanjšuje občutljivost ocene na šum najmanj zanesljive postaje. Dobitek je največji v smeri y , kjer ima nezanesljiva postaja 2 (varianca 0.1013, tabela 1) največji vpliv na geometrijo presečišča. To je pričakovano: WLS informacijo o različni zanesljivosti postaj izkoristi, neuteženi pristop pa jo zavrže.

Pri glavni lokalizaciji je utežena varianta potrebovala 13 iteracij, neutežena pa 7. To ni pomanjkljivost uteženega pristopa. Uteži $1/\sigma_i^2$ (od ≈ 10 za postajo 2 do ≈ 370 za postajo 3) močno spremenijo skaliranje kriterijske funkcije in ukrivljenost njene površine, zato isti začetni λ_0 ustreza drugačnemu razmerju med dušenjem in Gauss–Newtonovim korakom – metoda naredi nekaj več krajših, previdnejših korakov. Vsaka iteracija je računsko trivialna (rešitev sistema 2×2), obe varianti konvergirata v nekaj deset milisekundah, kakovost končne ocene pa je pri uteženi varianti boljša; nekaj dodatnih iteracij je zanemarljiva cena za približno prepolovljen standardni odklon.

6.3 Vloga logike sprejmi/zavrni

LM iteracija z logiko sprejmi/zavrni po sprejetih korakih garantira strogo padanje kriterija $J = \mathbf{F}^T \mathbf{W} \mathbf{F}$, s čimer je izključena možnost, da bi metoda sprejela korak, ki oceno poslabša. Brezpogojno sprejemanje korakov te lastnosti nima: položaj se posodobi tudi ob predolgem koraku, prilagoditev λ pa nastopi šele naknadno. Hkrati velja poudariti, kar smo videli na sliki 1: garancija se nanaša na kriterij, ne na posamezne koordinate. Začasni zavoje koordinate y v negativno območje je sprejet korak, ki je kriterij dejansko zmanjšal, in je zato povsem legitimen del konvergence, ne numerična napaka. V praksi se je varovalka $\lambda \leq 10^{10}$ izkazala za nepotrebno (nikoli ni bila sprožena), a je nujen del robustne implementacije.

7 Zaključek

V nalogi smo implementirali metodo nelinearnih najmanjših kvadratov z Levenberg–Marquardtovo optimizacijo za lokalizacijo mobilnega telefona iz šumnih meritev razdalj do treh baznih postaj, z metodološko doslednim pristopom: kriterijska funkcija $J = \mathbf{F}^T \mathbf{W} \mathbf{F}$ z utežmi $1/\sigma_i^2$ upošteva izmerjeno varianco meritev posameznih postaj, LM iteracija z logiko sprejmi/zavrni garantira monotono padanje kriterija, negotovost ocene pa je ovrednotena s pravilno mero – Monte Carlo varianco končnih ocen čez neodvisne ponovitve.

Glavna lokalizacija pri $N = 100$ je dala uteženo oceno položaja telefona

$$(x, y) = (5.2009, 2.0948)$$

v 13 iteracijah (neuteženo (5.2050, 2.1111) v 7 iteracijah). Monte Carlo analiza je kvantitativno potrdila teoretični zakon $1/N$: varianca ocene je pri $N = 100$ približno 104-krat (za x) oziroma 108-krat (za y) manjša kot pri $N = 1$. Primerjava pristopov je pokazala, da uteženje z inverznimi variancami meritev raztros ocene zmanjša za faktor 2 do 4 pri nespremenjenem povprečju, torej se splača vselej, ko lahko varianco meritev ocenimo. Skupaj rezultati potrjujejo, da je pravilno zastavljena metoda nelinearnih najmanjših kvadratov – z uteževanjem, nadzorovanim sprejemanjem korakov in korektno statistično oceno negotovosti – zanesljivo orodje za tovrstne lokalizacijske probleme.

Priloga: Koda

V prilogi je navedena celotna skripta, ki izvede glavno lokalizacijo (neuteženo in uteženo), Monte Carlo analizo vpliva števila meritev, primerjavo pristopov ter izriše vse slike in izdela vse tabele. Levenberg–Marquardtova metoda z logiko sprejmi/zavrni je implementirana v lokalni funkciji `run_lm` na dnu skripte.

```
1 clear all
2 close all
3 clc
4
5 % Ponovljivost
6 rng(42);
7
8 %% Ustvarjanje map, ce se ne obstajata
9 % Poti zasidramo na lokacijo skripte, zato se izhodi pisejo poleg nje,
10 % neodvisno od trenutne delovne mape.
11 script_dir = fileparts(mfilename('fullpath'));
12 if isempty(script_dir) % zascita, ce se skripta poganja po odsekih
13     script_dir = pwd;
14 end
15 fig_path = fullfile(script_dir, 'figs');
16 tab_path = fullfile(script_dir, 'tabs');
17 if ~exist(fig_path, 'dir'), mkdir(fig_path); end
18 if ~exist(tab_path, 'dir'), mkdir(tab_path); end
19
20 %% Koordinate baznih postaj
21 x1 = 1; y1 = 1;
22 x2 = 10; y2 = 5;
23 x3 = 2; y3 = 4;
24 base_stations = [x1 y1; x2 y2; x3 y3];
25
26 %% Skupni parametri optimizacije
27 lambda0 = 0.001;
28 max_iters = 1000;
29 tol = 1e-6;
30 lambda_max = 1e10; % varovalka pred neskoncno zanko zavrnitev
31 xy0 = [0, 0]; % zacetna ocena
32
33 %
34     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
35
36 %% DEL 1: GLAVNA LOKALIZACIJA (N = 100, neutezeni proti utezenemu LM)
37 %
38     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
39
40
41 fprintf('=====\n');
42 fprintf('DEL 1: GLAVNA LOKALIZACIJA\n');
43 fprintf('=====\n');
44
45 % Glavno stevilo meritev
46 N_main = 100;
47
48 % Surove meritve hranimo v vektorjih (ne le povprecja), da lahko ocenimo
49 % tudi varianco meritev
50 meritve1 = arrayfun(@(~) ping_stolp_1(), 1:N_main);
51 meritve2 = arrayfun(@(~) ping_stolp_2(), 1:N_main);
```

```

48 meritve3 = arrayfun(@(~) ping_stolp_3(), 1:N_main);
49
50 % Povprečje in varianca izmerjenih razdalj po postajah
51 d1 = mean(meritve1); var1 = var(meritve1);
52 d2 = mean(meritve2); var2 = var(meritve2);
53 d3 = mean(meritve3); var3 = var(meritve3);
54
55 d_main = [d1; d2; d3];
56 var_main = [var1; var2; var3];
57 std_main = sqrt(var_main);
58
59 fprintf('Statistika meritev po baznih postajah (N=%d):\n', N_main);
60 fprintf('Postaja | Povprec. | Varianca | Std\n');
61 for i = 1:3
62     fprintf('%7d | %9.4f | %9.4f | %8.4f\n', i, d_main(i), var_main(i),
        std_main(i));
63 end
64 fprintf('\n');
65
66 % Izvoz statistike postaj v tabelo LaTeX
67 tex_file_var = fullfile(tab_path, 'station_variance.tex');
68 fid = fopen(tex_file_var, 'w');
69 fprintf(fid, '\\begin{tabular}{|c|c|c|c|}\\hline\n');
70 fprintf(fid, 'Bazna postaja & Povpre \\v{c}je & \\bar{d}_i & Varianca & \\sigma_i^2 & Std & \\sigma_i \\\\hline\n');
71 for i = 1:3
72     fprintf(fid, '%d & %.4f & %.4f & %.4f \\\\hline\n', i, d_main(i),
        var_main(i), std_main(i));
73 end
74 fprintf(fid, '\\hline\\end{tabular}\n');
75 fclose(fid);
76 fprintf('Tabela LaTeX shranjena v: %s\n\n', tex_file_var);
77
78 % (a) Neutezeni LM: W = identiteta (vsem postajam zaupamo enako)
79 W_unw = eye(3);
80 [xy_unw, iters_unw, hist_unw] = run_lm(base_stations, d_main, W_unw, ...
81     xy0, lambda0, max_iters, tol, lambda_max);
82
83 % (b) Utezeni LM (WLS): W = diag(1/var_i) -> manj zanesljiva postaja
84 % (vecja varianca meritev) dobi manjšo utez
85 W_wls = diag(1 ./ var_main);
86 [xy_wls, iters_wls, hist_wls] = run_lm(base_stations, d_main, W_wls, ...
87     xy0, lambda0, max_iters, tol, lambda_max);
88
89 fprintf('Glavna lokalizacija z N=%d meritvami:\n', N_main);
90 fprintf('Neutezeni LM: (x,y) = (%.4f, %.4f), iteracij = %d\n', ...
91     xy_unw(1), xy_unw(2), iters_unw);
92 fprintf('Utezeni LM: (x,y) = (%.4f, %.4f), iteracij = %d\n\n', ...
93     xy_wls(1), xy_wls(2), iters_wls);
94
95 final_estimate = xy_wls; % utezena ocena je glavni rezultat
96 used_history = hist_wls;
97
98 %% Graf konvergence (glavna lokalizacija, utezeni LM)
99 figure;
100 subplot(2,1,1);
101 plot(1:size(used_history,1), used_history(:,1), 'b', 'LineWidth', 1.5);
102 xlabel('Sprejeti korak', 'Color', 'k');

```

```

103 ylabel('x', 'Color', 'k');
104 title(sprintf('Konvergenca x (N=%d, utežen LM)', N_main), 'Color', 'k'
105 );
106 grid on;
107 subplot(2,1,2);
108 plot(1:size(used_history,1), used_history(:,2), 'r', 'LineWidth', 1.5);
109 xlabel('Sprejeti korak', 'Color', 'k');
110 ylabel('y', 'Color', 'k');
111 title(sprintf('Konvergenca y (N=%d, utežen LM)', N_main), 'Color', 'k'
112 );
113 grid on;
114 ax = findall(gcf, 'Type', 'axes');
115 for i = 1:length(ax)
116     ax(i).XColor = 'k';
117     ax(i).YColor = 'k';
118     ax(i).GridColor = [0.7 0.7 0.7];
119     ax(i).Color = 'w';
120     ax(i).FontSize = 12;
121 end
122 set(gcf, 'Color', 'w');
123 saveas(gcf, fullfile(fig_path, 'main_convergence_plot.png'));
124
125 %% Graf geometrije (glavna lokalizacija)
126 figure; hold on; axis equal;
127 set(gcf, 'Color', 'w');
128 set(gca, 'Color', 'w');
129
130 plot(base_stations(:,1), base_stations(:,2), 'bo', ...
131      'MarkerSize', 10, 'DisplayName', 'Bazne postaje');
132
133 % Kroznice narisemo ročno (brez dodatnih orodij)
134 theta = linspace(0, 2*pi, 200);
135 plot(x1 + d1*cos(theta), y1 + d1*sin(theta), 'k', 'HandleVisibility', '
136 off');
137 plot(x2 + d2*cos(theta), y2 + d2*sin(theta), 'k', 'HandleVisibility', '
138 off');
139 plot(x3 + d3*cos(theta), y3 + d3*sin(theta), 'k', 'HandleVisibility', '
140 off');
141
142 plot(used_history(:,1), used_history(:,2), 'g--', ...
143      'LineWidth', 1.5, 'DisplayName', 'Pot optimizacije (utežena)');
144
145 plot(xy_unw(1), xy_unw(2), 'ms', ...
146      'MarkerSize', 12, 'LineWidth', 1.5, 'DisplayName', 'Ocena (neutežena
147 )');
148
149 plot(xy_wls(1), xy_wls(2), 'r*', ...
150      'MarkerSize', 12, 'DisplayName', 'Ocena (utežena)');
151
152 xlabel('x', 'Color', 'k');
153 ylabel('y', 'Color', 'k');
154 title(sprintf('Geometrijski prikaz lokalizacije (N=%d)', N_main), '
155 Color', 'k');
156 grid on;
157 ax = gca;

```

```

154 ax.GridColor = [0.6 0.6 0.6];
155 ax.XColor = 'k';
156 ax.YColor = 'k';
157 ax.FontSize = 12;
158
159 lgd = legend('Location', 'northeast');
160 lgd.TextColor = 'k';
161 lgd.Box = 'on';
162 lgd.Color = 'w';
163
164 saveas(gcf, fullfile(fig_path, 'main_geometry_plot.png'));
165
166 %
167     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
168 %% DEL 2: ANALIZA MERITEV ZA RAZLICNE N (varianca Monte Carlo)
169 %
170     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
171
172 fprintf('=====\n');
173 fprintf('DEL 2: ANALIZA MERITEV (Monte Carlo)\n');
174 fprintf('=====\n');
175
176 N_values = [1, 5, 10, 50, 100];
177 num_tests = length(N_values);
178 M = 100; % stevilo neodvisnih ponovitev na posamezen N
179
180 % OPOMBA: tu uporabimo neutezeno razlificio zaradi konsistentnosti cez
181 % use N:
182 % pri N = 1 variance meritev ni mogoce oceniti (varianca enega vzorca je
183 % 0),
184 % zato utezi 1/var_i ne bi bile definirane.
185
186 results_mean_xy = zeros(num_tests, 2); % povprecje koncnih ocen cez M
187 % zagonov
188 results_iters = zeros(num_tests, 1); % povprecno stevilo iteracij
189 results_mc_var = zeros(num_tests, 2); % varianca Monte Carlo KONCNIH
190 % ocen
191 all_estimates = zeros(M, 2, num_tests); % vse koncne ocene (za
192 % razsevni diagram)
193
194 for idx = 1:num_tests
195     N = N_values(idx);
196
197     est_N = zeros(M, 2);
198     iters_N = zeros(M, 1);
199
200     for m = 1:M
201         % Svezee neodvisne meritve za to ponovitev
202         dN = [mean(arrayfun(@(~) ping_stolp_1(), 1:N));
203               mean(arrayfun(@(~) ping_stolp_2(), 1:N));
204               mean(arrayfun(@(~) ping_stolp_3(), 1:N))];
205
206         [xy_m, k_m, ~] = run_lm(base_stations, dN, eye(3), ...
207                                 xy0, lambda0, max_iters, tol, lambda_max);
208
209         est_N(m, :) = xy_m;

```

```

203     iters_N(m) = k_m;
204 end
205
206 all_estimates(:, :, idx) = est_N;
207 results_mean_xy(idx, :) = mean(est_N, 1);
208 results_iters(idx) = mean(iters_N);
209 % Varianca Monte Carlo koncnih ocen cez M neodvisnih zagonov
210 % -> to je dejanska varianca ocene položaja
211 results_mc_var(idx, :) = var(est_N, 0, 1);
212
213 fprintf(['N=%3d-->povprecje(x,y)= (%.4f, %.4f), povpr. iteracij= %.1f, ...
214         'MCvarianca= (%.6f, %.6f)\n'], ...
215         N, results_mean_xy(idx,1), results_mean_xy(idx,2), results_iters
216         (idx), ...
217         results_mc_var(idx,1), results_mc_var(idx,2));
218 end
219 fprintf('\n');
220 % Izvoz rezultatov v tabelo LaTeX
221 tex_file = fullfile(tab_path, 'measurement_results.tex');
222 fid = fopen(tex_file, 'w');
223 fprintf(fid, '\\begin{tabular}{|c|c|c|c|c|c|c|}\\hline\n');
224 fprintf(fid, ['\\v{S}tevilomeritev(N)& Povpr. $x$& Povpr. $y$&
225         ...
226         'Povpr. \\v{s}t. iteracij& MCVar($x$)& MCVar($y$)&
227         \\\\hline\n']);
228 for i = 1:num_tests
229     fprintf(fid, '%d& %.4f& %.4f& %.1f& %.6f& %.6f\\\\n', ...
230             N_values(i), results_mean_xy(i,1), results_mean_xy(i,2), ...
231             results_iters(i), results_mc_var(i,1), results_mc_var(i,2));
232 end
233 fprintf(fid, '\\hline\\end{tabular}\n');
234 fclose(fid);
235 fprintf('Tabela LaTeX shranjena v: %s\n', tex_file);
236 %
237 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
238 %% DEL 3: PRIMERJAVA UTEZENEGA IN NEUTEZENEGA (N = 100, Monte Carlo)
239 %
240 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
241
242 fprintf('=====\n');
243 fprintf('DEL 3: PRIMERJAVA UTEZENEGA IN NEUTEZENEGA\n');
244 fprintf('=====\n');
245
246 M_cmp = 100;
247 N_cmp = 100;
248
249 est_unw_all = zeros(M_cmp, 2);
250 est_wls_all = zeros(M_cmp, 2);
251
252 for m = 1:M_cmp
253     % Sveze meritve; ISTE podatke uporabimo za obe razlicici
254     m1 = arrayfun(@(~) ping_stolp_1(), 1:N_cmp);
255     m2 = arrayfun(@(~) ping_stolp_2(), 1:N_cmp);

```

```

253     m3 = arrayfun(@(~) ping_stolp_3(), 1:N_cmp);
254
255     d_cmp = [mean(m1); mean(m2); mean(m3)];
256     v_cmp = [var(m1); var(m2); var(m3)];
257
258     [xy_a, ~, ~] = run_lm(base_stations, d_cmp, eye(3), ...
259         xy0, lambda0, max_iters, tol, lambda_max);
260     [xy_b, ~, ~] = run_lm(base_stations, d_cmp, diag(1 ./ v_cmp), ...
261         xy0, lambda0, max_iters, tol, lambda_max);
262
263     est_unw_all(m, :) = xy_a;
264     est_wls_all(m, :) = xy_b;
265 end
266
267 mean_unw = mean(est_unw_all, 1);    var_unw = var(est_unw_all, 0, 1);
268 mean_wls = mean(est_wls_all, 1);    var_wls = var(est_wls_all, 0, 1);
269 std_unw  = sqrt(var_unw);           std_wls  = sqrt(var_wls);
270
271 fprintf('Primerjava_cek_M=%d_ponovitev_(vsakic_N=%d):\n', M_cmp,
    N_cmp);
272 fprintf('Neutezeno: povprecje=(%.4f,%.4f), Var=(%.6f,%.6f), Std_
    =(%.4f,%.4f)\n', ...
273     mean_unw(1), mean_unw(2), var_unw(1), var_unw(2), std_unw(1),
274     std_unw(2));
275 fprintf('Utezeno: povprecje=(%.4f,%.4f), Var=(%.6f,%.6f), Std_
    =(%.4f,%.4f)\n\n', ...
276     mean_wls(1), mean_wls(2), var_wls(1), var_wls(2), std_wls(1),
277     std_wls(2));
278
279 % Izvoz primerjave v tabelo LaTeX
280 tex_file_cmp = fullfile(tab_path, 'weighted_comparison.tex');
281 fid = fopen(tex_file_cmp, 'w');
282 fprintf(fid, '\\begin{tabular}{|l|c|c|c|c|c|c|c|}\\hline\n');
283 fprintf(fid, ['Varianta_& Povpr._$x$& Povpr._$y$& Var($x$)& Var($y$)&
    & Std($x$)& Std($y$)\n\\hline\n']);
284 fprintf(fid, 'Neute\\v{z}eno_& %.4f_& %.4f_& %.6f_& %.6f_& %.4f_& %.4f_
    \\n\n', ...
285     mean_unw(1), mean_unw(2), var_unw(1), var_unw(2), std_unw(1),
286     std_unw(2));
287 fprintf(fid, 'Ute\\v{z}eno_(WLS)_& %.4f_& %.4f_& %.6f_& %.6f_& %.4f_&
    %.4f_\\n\n', ...
288     mean_wls(1), mean_wls(2), var_wls(1), var_wls(2), std_wls(1),
289     std_wls(2));
290 fprintf(fid, '\\hline\\end{tabular}\n');
291 fclose(fid);
292 fprintf('Tabela LaTeX shranjena v: %s\n\n', tex_file_cmp);
293
294 %% Razsewni diagram: oblaka ocen za obe razlicici
295 figure; hold on; axis equal;
296 plot(est_unw_all(:,1), est_unw_all(:,2), 'bo', ...
297     'MarkerSize', 5, 'DisplayName', 'Neutezene_ocene');
298 plot(est_wls_all(:,1), est_wls_all(:,2), 'rx', ...
299     'MarkerSize', 6, 'DisplayName', 'Utezene_ocene');
300 plot(mean_unw(1), mean_unw(2), 'bs', 'MarkerSize', 12, ...
301     'LineWidth', 2, 'DisplayName', 'Povprecje_(neutezeno)');
302 plot(mean_wls(1), mean_wls(2), 'rs', 'MarkerSize', 12, ...
303     'LineWidth', 2, 'DisplayName', 'Povprecje_(utezeno)');

```



```

301 xlabel('x', 'Color', 'k');
302 ylabel('y', 'Color', 'k');
303 title(sprintf('Utežene proti neuteženim ocenam (M=%d, N=%d)', M_cmp,
304             N_cmp), ...
305         'FontWeight', 'bold', 'Color', 'k');
306 grid on;
307
308 set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k', ...
309         'GridColor', [0.6 0.6 0.6], 'GridAlpha', 0.3, 'FontSize', 12);
310 l = legend('Location', 'best');
311 set(l, 'TextColor', 'k', 'Color', 'w', 'EdgeColor', 'k');
312 set(gcf, 'Color', 'w');
313 saveas(gcf, fullfile(fig_path, 'weighted_vs_unweighted.png'));
314
315 %
316     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
317
318 %% DEL 4: GRAFI ZA ANALIZO MERITEV
319 %
320     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
321
322 %% Graf 1: povprečno število iteracij v odvisnosti od N
323 figure;
324 bar(N_values, results_iters, 'FaceColor', [0.2 0.6 1]);
325 xlabel('Število meritev N', 'Color', 'k');
326 ylabel('Povprečno število iteracij do konvergence', 'Color', 'k');
327 title('Hitrost konvergence v odvisnosti od števila meritev', 'FontWeight',
328       'bold', 'Color', 'k');
329 set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
330 grid on;
331 set(gca, 'GridColor', [0.6 0.6 0.6], 'GridAlpha', 0.3);
332 set(gcf, 'Color', 'w');
333 saveas(gcf, fullfile(fig_path, 'iterations_vs_measurements.png'));
334
335 %% Graf 2: varianca Monte Carlo končnih ocen v odvisnosti od N
336 figure;
337
338 subplot(2,1,1);
339 plot(N_values, results_mc_var(:,1), 'bs-', 'LineWidth', 1.5, 'MarkerSize',
340      8);
341 xlabel('Število meritev N', 'Color', 'k');
342 ylabel('MC Var(x)', 'Color', 'k');
343 title('Varianca Monte Carlo končne ocene x v odvisnosti od N', 'Color',
344       'k');
345 grid on;
346
347 subplot(2,1,2);
348 plot(N_values, results_mc_var(:,2), 'rs-', 'LineWidth', 1.5, 'MarkerSize',
349      8);
350 xlabel('Število meritev N', 'Color', 'k');
351 ylabel('MC Var(y)', 'Color', 'k');
352 title('Varianca Monte Carlo končne ocene y v odvisnosti od N', 'Color',
353       'k');
354 grid on;
355
356 ax = findall(gcf, 'Type', 'axes');

```

```

349 for i = 1:length(ax)
350     ax(i).XColor = 'k';
351     ax(i).YColor = 'k';
352     ax(i).GridColor = [0.7 0.7 0.7];
353     ax(i).Color = 'w';
354     ax(i).FontSize = 12;
355 end
356 set(gcf, 'Color', 'w');
357 saveas(gcf, fullfile(fig_path, 'variance_vs_measurements.png'));
358
359 %% Graf 3: razsevni diagram koncnih ocen Monte Carlo za vsak N
360 figure; hold on; axis equal;
361 colors = lines(num_tests);
362 for idx = 1:num_tests
363     plot(all_estimates(:,1,idx), all_estimates(:,2,idx), '.', ...
364         'MarkerSize', 10, 'Color', colors(idx,:), ...
365         'DisplayName', sprintf('N=%d', N_values(idx)));
366 end
367
368 xlabel('x', 'Color', 'k');
369 ylabel('y', 'Color', 'k');
370 title(sprintf('Končne ocene Monte Carlo (M=%d zagonov na N)', M), ...
371     'FontWeight', 'bold', 'Color', 'k');
372 grid on;
373
374 set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k', ...
375     'GridColor', [0.6 0.6 0.6], 'GridAlpha', 0.3, 'FontSize', 12);
376 l = legend('Location', 'best');
377 set(l, 'TextColor', 'k', 'Color', 'w', 'EdgeColor', 'k');
378 set(gcf, 'Color', 'w');
379 saveas(gcf, fullfile(fig_path, 'mc_scatter.png'));
380
381 %
382     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
383
384 %% DEL 5: POVZETEK
385 %
386     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
387
388 fprintf('=====\n');
389 fprintf('POVZETEK\n');
390 fprintf('=====\n');
391 fprintf('Glavna lokalizacija (N=%d):\n', N_main);
392 fprintf('Neutezena ocena (%.4f, %.4f), iteracij=%d\n', ...
393     xy_unw(1), xy_unw(2), iters_unw);
394 fprintf('Utezena ocena (%.4f, %.4f), iteracij=%d\n\n', ...
395     xy_wls(1), xy_wls(2), iters_wls);
396
397 fprintf('Statistika meritev po postajah (N=%d):\n', N_main);
398 for i = 1:3
399     fprintf('Postaja %d: povprecje=%.4f, varianca=%.4f, std=%.4f\n', ...
400         i, d_main(i), var_main(i), std_main(i));
401 end
402 fprintf('\n');
403
404 fprintf('Analiza Monte Carlo (M=%d ponovitev na N):\n', M);

```

```

402 for i = 1:num_tests
403     fprintf(['_N=%3d:povprecje_(x,y)_(%.4f,%.4f),_povpr._
        iteracij_=%.1f,' ...
404         'MC_Var_=(%.6f,%.6f)\n'], ...
405         N_values(i), results_mean_xy(i,1), results_mean_xy(i,2), ...
406         results_iters(i), results_mc_var(i,1), results_mc_var(i,2));
407 end
408 fprintf('\n');
409
410 fprintf('Utezeno_proti_neutezenemu(M=_%d,_N=_%d):\n', M_cmp, N_cmp);
411 fprintf('_Neutezeno:povprecje_=(%.4f,%.4f),_Std_=(%.4f,%.4f)\n',
    ...
412     mean_unw(1), mean_unw(2), std_unw(1), std_unw(2));
413 fprintf('_Utezeno:___povprecje_=(%.4f,%.4f),_Std_=(%.4f,%.4f)\n\n',
    ...
414     mean_wls(1), mean_wls(2), std_wls(1), std_wls(2));
415
416 fprintf('Shranjene_slike:\n');
417 fprintf('___%s\n', fullfile(fig_path, 'main_convergence_plot.png'));
418 fprintf('___%s\n', fullfile(fig_path, 'main_geometry_plot.png'));
419 fprintf('___%s\n', fullfile(fig_path, 'weighted_vs_unweighted.png'));
420 fprintf('___%s\n', fullfile(fig_path, 'iterations_vs_measurements.png')
    );
421 fprintf('___%s\n', fullfile(fig_path, 'variance_vs_measurements.png'));
422 fprintf('___%s\n', fullfile(fig_path, 'mc_scatter.png'));
423 fprintf('Shranjene_tabele:\n');
424 fprintf('___%s\n', tex_file_var);
425 fprintf('___%s\n', tex_file);
426 fprintf('___%s\n', tex_file_cmp);
427 fprintf('=====\n');
428
429 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
430 %% LOKALNE FUNKCIJE
431 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
432
433 function [xy, iters, hist_xy] = run_lm(bs, d, W, xy0, lambda0, max_iters
    , tol, lambda_max)
434 % Levenberg-Marquardt z logiko sprejmi/zavrni in utezenim kriterijem.
435 % bs ... 3x2 koordinate baznih postaj
436 % d ... 3x1 (povprecene) izmerjene razdalje
437 % W ... 3x3 matrika utezi (eye(3) neutezeno, diag(1/var_i) za
    WLS)
438 % Korak je SPREJET le, ce se utezeni ostanek F'*W*F izboljsa; sicer se
439 % polozaj NE posodobi in lambda se poveca.
440 % hist_xy vsebuje zacetno tocko in vse SPREJETE korake.
441
442 xy = xy0;
443 lambda = lambda0;
444
445 hist_xy = zeros(max_iters + 1, 2);
446 hist_xy(1, :) = xy;
447 n_hist = 1;
448
449 k = 0;

```

```

450     for k = 1:max_iters
451         % Vektor ostankov in Jacobijeva matrika v trenutni točki
452         F = (xy(1) - bs(:,1)).^2 + (xy(2) - bs(:,2)).^2 - d.^2;
453         J = [2*(xy(1) - bs(:,1)), 2*(xy(2) - bs(:,2))];
454
455         crit = F' * W * F;    % utezena kvadratna norma ostanka
456
457         % Kandidatni korak Levenberg-Marquardt
458         step = (J' * W * J + lambda * eye(2)) \ (-J' * W * F);
459         xy_new = xy + step';
460
461         % Utezeni ostanek v kandidatni točki
462         F_new = (xy_new(1) - bs(:,1)).^2 + (xy_new(2) - bs(:,2)).^2 - d
463             .^2;
464         crit_new = F_new' * W * F_new;
465
466         if crit_new < crit
467             % Izboljsanje -> korak SPREJMEMO
468             xy = xy_new;
469             n_hist = n_hist + 1;
470             hist_xy(n_hist, :) = xy;
471             lambda = lambda / 10;
472
473             if norm(step) < tol
474                 break;
475             end
476         else
477             % Ni izboljsanja -> korak ZAVRNEMO (ostanemo v xy), povečamo
478             % lambda
479             lambda = lambda * 10;
480
481             if lambda > lambda_max
482                 fprintf('OPOMBA: lambda je presežla %.0e, LM se
483                     predcasno ustavi.\n', lambda_max);
484                 break;
485             end
486         end
487     end
488
489     iters = k;
490     hist_xy = hist_xy(1:n_hist, :);
491 end

```