

Vaja 3 – LSE, PCA in PCR analiza

Gašper Leskovec

27. julij 2026

1 Uvod

V nalogi analiziramo identifikacijo modela za proces oksidacije amoniaka v dušikovo kislino z uporabo treh metod identifikacije:

- metoda najmanjših kvadratov (LSE – Least Squares Estimation),
- analiza glavnih komponent (PCA – Principal Component Analysis),
- regresija na glavnih komponentah (PCR – Principal Component Regression).

Vhodne spremenljivke procesa so pretok zraka za hlajenje A_{FLOW} , temperatura vode T_{H_2O} in koncentracija kisline C_{ACID} , izhodna spremenljivka pa je inverzna vrednost izkoristka I_{EFF} . Ker gre za inverzno vrednost, večja vrednost I_{EFF} pomeni *slabši* izkoristek procesa – to je treba upoštevati pri branju predznakov parametrov modela.

Naloga je razdeljena na dva dela:

- **Del 1:** primerjava LSE in PCA glede na vpliv standardizacije podatkov,
- **Del 2:** problem kolinearnosti vhodov in primerjava LSE in PCR kot dveh načinov spopadanja z njim.

Rezultati v tem poročilu so pridobljeni z MATLAB implementacijo opisane metodologije; vsi grafi in tabele so generirani neposredno iz izhodov skripte.

2 Teoretično ozadje

2.1 LSE – metoda najmanjših kvadratov

Za model z absolutnim (prostim) členom predpostavimo linearno obliko

$$y = a_1x_1 + a_2x_2 + a_3x_3 + r = \boldsymbol{\varphi}^T \boldsymbol{\theta}$$
$$\boldsymbol{\varphi} = [x_1, x_2, x_3, 1]^T, \quad \boldsymbol{\theta} = [a_1, a_2, a_3, r]^T.$$

Za N meritev zapišemo $\mathbf{y} = \Phi\boldsymbol{\theta} + \mathbf{e}$, kjer vrstice Φ vsebujejo $\boldsymbol{\varphi}^T$. Minimizacija vsote kvadratov napak $J(\boldsymbol{\theta}) = \mathbf{e}^T \mathbf{e}$ vodi do *normalnih enačb*

$$\Phi^T \Phi \boldsymbol{\theta} = \Phi^T \mathbf{y} \implies \boldsymbol{\theta} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}.$$

LSE minimizira izključno *navpično* (vertikalno) napako v smeri y – vhodne spremenljivke x_i obravnava kot brez šuma.

2.2 PCA – implicitni model hiperravnine

Pri PCA v Delu 1 sestavimo razširjeno matriko $\mathbf{Z} = [\mathbf{X} \ \mathbf{y}]$ (vse spremenljivke, vhodi IN izhod, enakovredno). Iz centrirane kovariančne matrike $\mathbf{F} = \frac{1}{N-1}(\mathbf{Z} - \mathbf{v})(\mathbf{Z} - \mathbf{v})^T$ (kjer je $\mathbf{v}$ vektor povprečij) izračunamo lastne vrednosti in lastne vektorje. Model je implicitna hiperravnina

$$\mathbf{p}^T(\mathbf{z} - \mathbf{v}) = 0,$$

kjer je $\mathbf{p}$ lastni vektor pri **najmanjši** lastni vrednosti $\mathbf{F}$. Geometrijsko: $\mathbf{p}$ kaže v smer *najmanjše variance* podatkovnega oblaka $[\mathbf{X}, \mathbf{y}]$ – to je smer, pravokotno na katero je oblak najbolj šploščen”, torej normala na ravnino, ki se najboljše prilega podatkom v smislu najmanjše *pravokotne* (ortogonalne) razdalje. Ta pristop se imenuje tudi *total least squares* (TLS), ker minimizira napako v VSEH smereh hkrati, ne le v y .

Implicitno obliko pretvorimo v eksplicitno z ločitvijo zadnje komponente p_{n+1} (pripadajoče y):

$$a_i = -\frac{p_i}{p_{n+1}}, \quad r = \frac{\mathbf{p}^T \mathbf{v}}{p_{n+1}} \implies y = \mathbf{a}^T \mathbf{x} + r.$$

2.3 PCA (Del 1) vs. PCR (Del 2) – eksplicitna primerjava

Čeprav obe metodi uporabljata isto matematično orodje (lastno razčlenitev / eigen-dekompozicijo kovariančne matrike), gre za **dve različni uporabi z nasprotno logiko izbire lastnega vektorja**, kar eksplicitno strnemo v tabeli 1.

Tabela 1: Eksplicitna primerjava PCA (Del 1) in PCR (Del 2).

	PCA (Del 1)	PCR (Del 2)
Vhodni podatki	vse spremenljivke $[\mathbf{X}, \mathbf{y}]$	samo vhodi $\mathbf{X}$ (brez $\mathbf{y}$)
Izbira lastnega vektorja	obdrži najmanjšo lastno vrednost	odstrani najmanjšo lastno vrednost
Vloga izbrane komponente	je normala modela (implicitna ravnina)	se zavrže kot redundantna
Regresija	ni potrebna (model je implicitna ravnina)	LSE na preostalih (največjih) komponentah
Namen	prileganje total-least-squares	odprava kolinearnosti pred LSE regresijo

Pri PCR torej najprej izvedemo PCA na $\mathbf{X}$, odstranimo komponento z najmanjšo lastno vrednostjo (ki pri kolinearnih vhidih ustreza smeri "redundance" med skoraj linearno odvisnima spremenljivkama), nato pa izvedemo navadno LSE regresijo v prostoru preostalih glavnih komponent in parametre preslikamo nazaj v prostor vhodnih spremenljivk.

2.4 Numerika: $\text{inv}()$ proti operatorju $\backslash$

Za reševanje linearnega sistema $\mathbf{A}\boldsymbol{\theta} = \mathbf{b}$ (npr. normalnih enačb) je numerično bolje uporabiti $\boldsymbol{\theta} = \mathbf{A} \backslash \mathbf{b}$ kot $\boldsymbol{\theta} = \text{inv}(\mathbf{A})\mathbf{b}$: operator $\backslash$ v MATLAB-u izbere ustrezno matrično razčlenitev (npr. Choleskega za simetrično pozitivno definitno $\mathbf{A}$) in se izogne eksplicitni tvorbi inverza, kar je hitreje in numerično stabilneje, še posebej če je $\mathbf{A}$ blizu singularne. To postane pomembno predvsem pri izračunu kovariančne matrike ocenjenih parametrov ($\text{Cov} = \sigma^2(\mathbf{A})^{-1}$), kjer je $\text{inv}(\mathbf{A})$ nadomeščen z $\mathbf{A} \backslash \mathbf{I}$.

Pomemben diagnostični kazalnik numerične zanesljivosti je *pogojenostno število* (angl. condition number) $\text{cond}(\mathbf{A}) = \sigma_{\max}(\mathbf{A})/\sigma_{\min}(\mathbf{A})$. Visoko pogojenostno število ($\gg 1$) pomeni, da je rešitev sistema zelo občutljiva na majhne motnje v podatkih – to je natanko simptom kolinearnosti, ki ga obravnavamo v Delu 2.

3 Metodologija

V Delu 1 primerjamo LSE in PCA na treh različnih standardizacijah vhodnih in izhodnih podatkov: Min-Max na $[0, 1]$, Z-score (standardizacija na ničelno povprečje in enotsko varianco) in brez standardizacije. Modela sta v vsakem primeru ocenjena v standardiziranem prostoru, nato pa transformirana nazaj v *originalni* prostor (enote procesa), da je primerjava smiselna in neodvisna od izbrane standardizacije.

V Delu 2 dodamo umetno kolinearno spremenljivko $X_{new} = 2T_{H2O} + 6 + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0.1^2)$, standardiziramo vse štiri vhode (Z-score) in primerjamo LSE (brez prostega člena) s PCR. Eksperiment ponovimo 100-krat (različni vzorci šuma ε), da eksperimentalno ocenimo varianco parametrov obeh metod.

4 Rezultati – Del 1: vpliv standardizacije

4.1 Modeli v originalnem prostoru

Spodaj so enačbe modelov, izračunane iz ocenjenih parametrov v originalnem prostoru, za LSE in PCA, pri vseh treh standardizacijah:

LSE, Min-Max: $y = 0.7156 A_{FLOW} + 1.2953 T_{H2O} - 0.1521 C_{ACID} - 39.9197$

LSE, Z-Score: $y = 0.7156 A_{FLOW} + 1.2953 T_{H2O} - 0.1521 C_{ACID} - 39.9197$

LSE, brez std.: $y = 0.7156 A_{FLOW} + 1.2953 T_{H2O} - 0.1521 C_{ACID} - 39.9197$

PCA, Min-Max: $y = 0.7989 A_{FLOW} + 1.2072 T_{H2O} - 0.2188 C_{ACID} - 37.3408$

PCA, Z-Score: $y = 0.7988 A_{FLOW} + 1.2134 T_{H2O} - 0.2159 C_{ACID} - 37.7156$

PCA, brez std.: $y = 0.4074 A_{FLOW} + 2.5035 T_{H2O} - 0.1792 C_{ACID} - 44.4450$

Že na prvi pogled je vidno: LSE parametri so **identični** pri vseh treh standardizacijah, PCA parametri pa se **znatno razlikujejo**, še posebej v primeru brez standardizacije. To je natančno kvantificirano v razdelku 4.6.

Tabela 2: Parametri LSE in PCA modelov v originalnem prostoru.


Standardizacija	a_1	a_2	a_3	r
<i>LSE</i>				
Min-Max [0, 1]	0.7156	1.2953	-0.1521	-39.9197
Z-Score	0.7156	1.2953	-0.1521	-39.9197
Brez	0.7156	1.2953	-0.1521	-39.9197
<i>PCA</i>				
Min-Max [0, 1]	0.7989	1.2072	-0.2188	-37.3408
Z-Score	0.7988	1.2134	-0.2159	-37.7156
Brez	0.4074	2.5035	-0.1792	-44.4450

Tabela 3: Teoretična varianca LSE parametrov v originalnem prostoru (Del 1).


Standardizacija	$\text{var}(a_1)$	$\text{var}(a_2)$	$\text{var}(a_3)$	$\text{var}(r)$
Min-Max [0, 1]	0.018187	0.135442	0.024428	141.5147
Z-Score	0.018187	0.135442	0.024428	141.5147
Brez	0.018187	0.135442	0.024428	141.5147

Teoretična varianca parametrov je izračunana iz $\text{Cov} = \sigma^2(\Phi_{std}^T \Phi_{std})^{-1}$ v standardiziranem prostoru in nato transformirana v originalni prostor. Vrednosti so **identične** pri vseh treh standardizacijah – ne le podobne, temveč do prikazane natančnosti popolnoma enake. To je neodvisna potrditev iste ugotovitve kot v razdelku 4.6: LSE je robusten na standardizacijo podatkov, kar se kaže tako v *enakih ocenjenih parametrih* kot v *enaki teoretični varianci teh parametrov* – gre torej za en pojav (afina invariantnost LSE), potrjen z dvema neodvisnima dokazoma.


4.2 Napake modelov




Slika 1: Primerjava NRMSE: LSE vs. PCA, za vse tri standardizacije.



Slika 2: Primerjava biasa (povprečne napake): LSE vs. PCA.



Slika 3: Primerjava konsistentnosti (std napake): LSE vs. PCA.




Slika 4: Primerjava vseh štirih parametrov (a_1, a_2, a_3, r) med metodama in standardizacijami.

Tabela 4: Metrike napake v originalnem prostoru (bias, std napake, NRMSE, ortogonalni RMSE v standardiziranem prostoru).

Standardizacija	LSE				PCA			
	bias	std	NRMSE	orthRMSE	bias	std	NRMSE	orthRMSE
Min-Max	3.4×10^{-16}	2.9902	0.2869	0.0676	1.3×10^{-14}	3.0335	0.2910	0.0668
Z-Score	1.1×10^{-14}	2.9902	0.2869	0.2279	-2.0×10^{-15}	3.0343	0.2911	0.2250
Brez	0	2.9902	0.2869	1.6280	1.4×10^{-15}	3.8255	0.3670	1.3663

4.3 Porazdelitev napake

Povprečje in standardni odklon povesta le prva dva momenta napake, ne pa njene oblike. Sliki 5 zato prikazujeta histograma napake $e = y - \hat{y}$ v originalnem prostoru za LSE in PCA pri standardizaciji z-score.



Slika 5: Porazdelitev napake $e = y - \hat{y}$ v originalnem prostoru pri standardizaciji z-score, levo LSE, desno PCA. Črtkana črta označuje $e = 0$, polna povprečje napake.

Obe porazdelitvi sta centrirani okoli ničle: povprečna napaka znaša $1,1 \cdot 10^{-14}$ pri LSE in $-2,0 \cdot 10^{-15}$ pri PCA, kar je na nivoju numerične natančnosti in potrjuje, da sta modela nepristranska. Razpršenost je pri obeh primerljiva (standardni odklon 2,9902 pri LSE proti 3,0343 pri PCA), kar pomeni, da razlika med metodama ni v sistematičnem odstopanju, temveč kvečjemu v obliki repov. Za nepristranskost je bistveno, da je masa porazdelitve razporejena simetrično okoli ničle; morebitna asimetrija bi pomenila, da model v določenem delu delovnega območja sistematično odstopa, česar povprečna napaka blizu nič sama po sebi ne bi razkrila.

4.4 Diskusija: kaj pove bias in kateri model je boljši?

Bias (pristranskost) je definiran kot povprečna vrednost napake modela, $\text{bias} = \bar{e} = \overline{y - \hat{y}}$. Vrednost blizu 0 pomeni nepristranski model – model v povprečju ne precenjuje ali podcenjuje izhoda.

Iz tabele 4 je razvidno, da je bias **obeh** modelov (LSE in PCA), pri **vseh** treh standardizacijah, reda velikosti 10^{-14} do 10^{-16} – to je raven *numeričnega zaokroževanja* plavajoče vejice (float), ne dejanska modelska razlika. Pravilna interpretacija torej ni "kateri model ima manjši bias" (ker

sta oba praktično enaka in enaka nič), temveč: **oba modela sta v tem primeru nepristranska**, kar je pričakovano, saj oba LSE in PCA (implicitni model preko hiperravnine) po konstrukciji potekata skozi povprečje podatkov. Bias torej v Delu 1 *ni* razlikovalni kriterij med metodama.

Pravi kriterij za izbiro modela sta zato **std(napake)** (konsistentnost oz. varianca napake) in **NRMSE** (normalizirana natančnost). Iz tabele 4 vidimo, da je LSE pri *vseh treh* standardizacijah enako dober ali boljši od PCA po obeh teh kriterijih (npr. Min-Max: std 2.9902 proti 3.0335, NRMSE 0.2869 proti 0.2910; razlika se še poveča brez standardizacije: std 2.9902 proti 3.8255, NRMSE 0.2869 proti 0.3670).

Zaključek Dela 1 (utemeljeno priporočilo): priporočen model je **LSE** – ne zaradi biasa (ta ne razlikuje metod), temveč zaradi dosledno manjšega ali enakega std(napake) in NRMSE pri vseh preizkušanih standardizacijah.

4.5 Zakaj je PCA po NRMSE slabši? – ni napaka metode

To ne pomeni, da je PCA slaba ali napačna metoda – gre za posledico **drugačnega kriterija optimizacije**. LSE minimizira izključno *navpično* (vertikalno) napako v smeri y , medtem ko PCA/TLS minimizira *pravokotno* (ortogonalno) napako v skupnem prostoru $[\mathbf{X}, \mathbf{y}]$. NRMSE meri ravno navpično napako – po TEM kriteriju je LSE po definiciji vedno enako dober ali boljši, saj je LSE prav ta kriterij eksaktno minimiziral.

To smo preverili tudi numerično: v tabeli 4 je dodan stolpec *orthRMSE* – ortogonalni RMSE do prilegajoče hiperravnine v standardiziranem prostoru $[\mathbf{X}, \mathbf{y}]$. Slika je obratna: pri vseh treh standardizacijah je PCA po tem (svojem lastnem) kriteriju enako dober ali boljši od LSE (npr. Min-Max: 0.0668 proti 0.0676; brez standardizacije: 1.3663 proti 1.6280). To potrjuje, da noben model ni "napačen" – gre le za dva različna, veljavna kriterija prileganja.

4.6 Kvantificirana robustnost LSE in občutljivost PCA na standardizacijo

V nadaljevanju numerično dokažemo, da je LSE robusten na standardizacijo, PCA pa je nanjo občutljiv: za vsak parameter (a_1, a_2, a_3, r) smo izračunali razpon (max–min, kar je za tri vrednosti enako maksimalni paroma razliki) med tremi standardizacijami:

$$\text{LSE razpon} = \max_i (\theta_{\text{Min-Max}}^{(i)} - \theta_{\text{Z-Score}}^{(i)}, \dots)$$

$$\text{LSE razpon} = [1.33 \times 10^{-15}, 2.00 \times 10^{-15}, 3.41 \times 10^{-15}, 3.48 \times 10^{-13}]$$

$$\text{PCA razpon} = [0.3915, 1.2964, 0.0396, 7.1042]$$

Največja razlika kjerkoli za LSE je 3.48×10^{-13} – praktično nič (numerični šum), medtem ko je za PCA največja razlika 7.10 (parameter r) – za **13 redov velikosti** večja. To je neposreden numerični dokaz, da je LSE robusten na standardizacijo podatkov, PCA pa je nanjo občutljiv.


Zakaj je temu tako? LSE minimizira navpično napako, kar je afin-invariantna lastnost linearne regresije: transformacija $x \rightarrow (x - \text{shift})/\text{scale}$ je afina, zato optimalna rešitev, preslikana nazaj, da isti model ne glede na izbrano afino transformacijo. PCA pa temelji na relativnih razmerjih varianc med spremenljivkami (lastne vrednosti kovariančne matrike $[\mathbf{X}, \mathbf{y}]$) – če spremenljivke niso na primerljivi skali (npr. brez standardizacije, kjer ima r v originalnih enotah bistveno večjo varianco kot npr. C_{ACID}), bo smer najmanjše variance dominirana s spremenljivko z najmanjšo absolutno varianco, kar ni nujno smiselna "šumnašmer" modela.

5 Rezultati – Del 2: problem kolinearnosti

Dodali smo novo, umetno kolinearno spremenljivko

$$X_{new} = 2T_{H2O} + 6 + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 0.1^2).$$

5.1 Korelacija



Slika 6: Korelacijska matrika standardiziranih kolinearnih vhodov.

Tabela 5: Korelacijska matrika standardiziranih vhodov (Del 2).

	A_{FLOW}	T_{H2O}	C_{ACID}	X_{new}
A_{FLOW}	1.0000	0.7819	0.5001	0.7827
T_{H2O}	0.7819	1.0000	0.3909	0.9999
C_{ACID}	0.5001	0.3909	1.0000	0.3940
X_{new}	0.7827	0.9999	0.3940	1.0000

Korelacija med T_{H2O} in X_{new} je $\text{corr}(T_{H2O}, X_{new}) \approx 0.9999$ – praktično popolna kolinearnost, kot je bilo pričakovano po konstrukciji X_{new} .

5.2 Parametri modelov – standardizirani in originalni prostor

Parametri modelov LSE in PCR so prikazani tako v standardiziranem kot v originalnem prostoru, saj je slednji edini, v katerem imajo koeficienti neposreden fizikalen pomen.

Standardiziran prostor (brez prostega člena):

$$\text{LSE: } y = 0.6449 A_{FLOW} + 0.1245 T_{H2O} - 0.0811 C_{ACID} + 0.2786 X_{new}$$

$$\text{PCR: } y = 0.6449 A_{FLOW} + 0.2016 T_{H2O} - 0.0809 C_{ACID} + 0.2013 X_{new}$$

Opazimo tudi, da PCR koeficienta pri kolinearnem paru ($a_2 = 0.2016$ za T_{H2O} in $a_4 = 0.2013$ za X_{new}) med seboj **skoraj sovpadata** – PCR torej razdeli skupni vpliv kolinearnega para praktično enakomerno med obe spremenljivki. LSE tega ne naredi: njegova koeficienta ($a_2 = 0.1245$, $a_4 = 0.2786$) sta si med seboj precej različna, saj LSE med kolinearnima vhodoma nima nobenega mehanizma, ki bi vsiljeval simetrično porazdelitev vpliva. *Originalni prostor:*

$$\text{LSE: } y = 0.7154 A_{FLOW} + 0.4005 T_{H2O} - 0.1540 C_{ACID} + 0.4485 X_{new} - 42.4739$$

$$\text{PCR: } y = 0.7155 A_{FLOW} + 0.6489 T_{H2O} - 0.1535 C_{ACID} + 0.3240 X_{new} - 41.7654$$

Tabela 6: Parametri LSE in PCR (kolinearni primer) v originalnem prostoru.

	a_1	a_2	a_3	a_4	r
LSE	0.7154	0.4005	-0.1540	0.4485	-42.4739
PCR	0.7155	0.6489	-0.1535	0.3240	-41.7654

Opazanje: pojav prostega člena po transformaciji. Modela sta bila v standardiziranem prostoru ocenjena **brez** prostega člena ($y_{std} = \mathbf{a}_{std}^T \mathbf{x}_{std}$), vendar po transformaciji nazaj v originalni prostor dobila **neničeln** prosti člen ($r_{LSE} \approx -42.47$, $r_{PCR} \approx -41.77$). To ni napaka – posledica je afinosti standardizacije: ker je z-score transformacija $x_{std} = (x - \bar{x})/\sigma_x$ afina preslikava z na splošno neničelnim povprečjem $\bar{x}$, se pri poenostavitvi nazaj v originalne enote pojavi člen $r_{orig} = \bar{y} - \sum_i a_{orig,i} \bar{x}_i$, ki ni nič, razen če je ravno $\bar{y} = \sum_i a_{orig,i} \bar{x}_i$. "Brez prostega člena" je torej lastnost samo tega specifičnega (premaknjenega in skaliranega) koordinatnega sistema, ne pa inherentna lastnost razmerja med x in y .

5.3 Numerika: pogojenostno število – Del 1 proti Delu 2

Pogojenostno število matrike normalnih enačb je neposreden pokazatelj (ne)kolinearnosti:

- Del 1, Z-Score: $\text{cond}(\Phi_{std}^T \Phi_{std}) \approx 1.03 \times 10^1$ (red velikosti 10^1 – dobro pogojena matrika, vhodi so med seboj razmeroma neodvisni).
- Del 2, kolinearni primer: $\text{cond}(\mathbf{X}_{col,std}^T \mathbf{X}_{col,std}) \approx 2.47 \times 10^4$ (red velikosti 10^4 – približno **2400-krat** večje pogojenostno število kot v Delu 1).

Ta skok za več redov velikosti je numerični podpis kolinearnosti: majhne spremembe v podatkih (npr. šum ε v X_{new}) se pri reševanju normalnih enačb ojačajo v veliko večje spremembe ocenjenih parametrov – kar natanko opazimo pri LSE v naslednjih razdelkih.

5.4 Vsota parametrov: standardiziran proti originalnemu prostoru

Ker je X_{new} konstruiran kot $X_{new} = 2 T_{H2O} + 6 + \varepsilon$, bi pričakovali, da model "prepozna" to redundanco tako, da je kombiniran prispevek T_{H2O} in X_{new} podoben prispevku samega T_{H2O} v osnovnem (3-vhodnem) modelu brez kolinearnosti. Vendar razmerje med T_{H2O} in X_{new} v **originalnih enotah** NI 1:1, temveč **1:2** (zaradi faktorja 2 v definiciji X_{new}) – zato je treba to preverjanje izvesti pravilno, ločeno v dveh prostorih.

V standardiziranem (z-score) prostoru preverjanje je neposredno, brez korekcije, ker z-score standardizacija obe spremenljivki (T_{H2O} in X_{new}) skalira na enotsko varianco – faktor 2 iz definicije X_{new} se s tem "absorbira" v razmerje standardnih odklonov in izgine:

$$a_{2,baseline,std} = 0.4025$$

$$a_{2,LSE,std} + a_{4,LSE,std} = 0.1245 + 0.2786 = 0.4031$$

(za PCR: $0.2016 + 0.2013 = 0.4029$) – obe vsoti se dobro ujemata z izhodiščno vrednostjo 0.4025.

V originalnem prostoru pa je treba prispevek X_{new} uteži z ustreznim faktorjem 2, saj 1 enota X_{new} v originalnih enotah ustreza 2 enotama T_{H_2O} :

$$a_{2,baseline,orig} = 1.2953.$$

Brez korekcije (samo $a_{2,orig} + a_{4,orig}$) se vsoti **ne ujemata**:

$$\text{LSE: } 0.4005 + 0.4485 = 0.8490 \quad (\text{razlika od } 1.2953!)$$

$$\text{PCR: } 0.6489 + 0.3240 = 0.9729 \quad (\text{razlika od } 1.2953!)$$


S korekcijo za faktor 2 ($a_{2,orig} + 2 \cdot a_{4,orig}$) pa se ujemanje povrne:

$$\text{LSE: } 0.4005 + 2 \cdot 0.4485 = 1.2975 \quad (\approx 1.2953, \checkmark)$$

$$\text{PCR: } 0.6489 + 2 \cdot 0.3240 = 1.2970 \quad (\approx 1.2953, \checkmark)$$

To je netrivialna, a pomembna ugotovitev: preverjanje "vsota parametrov ostane konstantna" je smiselno in neposredno le v standardiziranem prostoru (kjer standardizacija implicitno normira razmerje med kolinearnima spremenljivkama), v originalnem prostoru pa je treba upoštevati dejansko linearno razmerje (tu: faktor 2) iz definicije kolinearne spremenljivke.

5.5 Prispevek spremenljivk h glavnim komponentam




Slika 7: Prispevki (%) posameznih vhodnih spremenljivk k prvima dvema (obdržanima) glavnima komponentama.

Tabela 7: Prispevki spremenljivk h glavnima komponentama P_1 in P_2 [%].


	P_1 [%]	P_2 [%]
A_{FLOW}	26.44	0.63
T_{H_2O}	27.93	19.56
C_{ACID}	17.68	60.49
X_{new}	27.96	19.31

T_{H_2O} in X_{new} imata v obeh prikazanih komponentah skoraj identičen prispevek (27.93 % proti 27.96 % v P_1 , 19.56 % proti 19.31 % v P_2), kar dodatno potrjuje njuno kolinearnost – z vidika PCA sta si spremenljivki praktično neločljivi.

5.6 Eksperimentalna proti teoretični varianci parametrov



Slika 8: Primerjava parametrov LSE in PCR za en reprezentativen zagon.




Slika 9: Eksperimentalna varianca parametrov (100 ponovitev) – LSE proti PCR.

Tabela 8: Eksperimentalna (100 ponovitev) in teoretična varianca parametrov (kolinearni primer, standardiziran prostor).

Parameter	LSE (teor. var.)	LSE (eksp. var.)	PCR (eksp. var.)
a_1	0.014783	0.001026	3.01×10^{-6}
a_2	20.985215	24.273	2.05×10^{-6}
a_3	0.007046	0.000218	5.32×10^{-7}
a_4	21.058784	24.273	5.38×10^{-6}
povprečje	10.517	12.137	2.74×10^{-6}

Teoretična varianca LSE parametrov (iz $\text{Cov} = \sigma^2(\mathbf{X}_{col,std}^T \mathbf{X}_{col,std})^{-1}$) je za a_2 in a_4 (20.99 oz. 21.06) istega reda velikosti kot eksperimentalno ocenjena varianca (24.27 za oba), kar potrjuje konsistentnost teoretičnega izračuna z eksperimentom; za a_1 in a_3 (koeficienta A_{FLOW} in C_{ACID} , ki nista udeležena v kolinearnosti) je teoretična varianca za rede velikosti manjša (0.0148 oz. 0.0070), prav tako skladno z eksperimentom. Povprečna eksperimentalna varianca LSE parametrov (12.14) je za **približno 6 redov velikosti** večja od povprečne variance PCR parametrov (2.74×10^{-6}) – PCR z odstranitvijo redundantne komponente drastično stabilizira ocenjene parametre.

5.7 Napaka modela sama po sebi ne razkrije kolinearnosti



Slika 10: Levo: NRMSE modela LSE in PCR je praktično enak. Desno: eksperimentalna varianca parametrov (logaritemska skala) se razlikuje za rede velikosti. Napaka modela torej ne razkrije problema kolinearnosti – razkrije ga šele analiza variance/stabilnosti parametrov.

Tabela 9: Bias, std napake in NRMSE – LSE proti PCR, kolinearni primer.

	bias	std(napaka)	NRMSE
LSE	-5.3×10^{-18}	0.29395	0.28686
PCR	-5.8×10^{-17}	0.29395	0.28686

To je ključna ugotovitev Dela 2: NRMSE LSE (0.28686) je **praktično enak** NRMSE PCR (0.28686) – gledano samo skozi napako modela na razpoložljivih podatkih, bi sklepali, da sta modela enakovredna in da ni nobenega problema. Vendar je povprečna eksperimentalna varianca parametrov LSE (12.14) za **približno 6 redov velikosti** večja od PCR (2.74×10^{-6}) – LSE parametri so torej skrajno nestabilni (majhna sprememba šuma v X_{new} popolnoma spremeni razdelitev prispevka med T_{H2O} in X_{new} , glej razdelek 5.4), kar iz same napake modela ni razvidno. **Zaključek: metrika napake (NRMSE) je nujna, a ne zadostna diagnostika – za odkrivanje kolinearnosti je treba analizirati tudi varianco/stabilnost ocenjenih parametrov** (npr. s ponovljenimi zagoni ali s pogojenostnim številom, glej razdelka prej).

6 Zaključek

Rezultati analize kažejo:

- V Delu 1 sta LSE in PCA oba nepristranska ($\text{bias} \approx 0$, na nivoju numeričnega šuma) – bias torej ni kriterij, ki bi med njima ločil. Ločevalna kriterija sta $\text{std}(\text{napake})$ in NRMSE, po katerih je LSE dosledno enak ali boljši od PCA pri vseh treh standardizacijah – zato je za ta podatkovni niz priporočen model **LSE**.
- LSE je numerično dokazano robusten na izbiro standardizacije ($\max |\Delta\theta| \approx 3.5 \times 10^{-13}$), PCA pa je nanjo občutljiv ($\max |\Delta\theta| \approx 7.10$) – razlog je afina invariantnost LSE v primerjavi z PCA, ki temelji na relativnih razmerjih varianc.
- PCA ni slabša metoda – le optimizira drugačen (ortogonalni) kriterij od NRMSE; to potrjuje uvedena metrika orthRMSE .
- V Delu 2 skoraj popolna kolinearnost ($\text{corr}(T_{H_2O}, X_{\text{new}}) \approx 0.9999$) povzroči skok pogojenostnega števila iz reda 10^1 na red 10^4 in posledično skrajno nestabilne LSE parametre (eksperimentalna varianca ≈ 12.14).
- PCR z odstranitvijo redundantne (najmanjše) glavne komponente pred regresijo to nestabilnost odpravi (eksperimentalna varianca $\approx 2.74 \times 10^{-6}$), ob praktično enakem NRMSE kot LSE.
- Vsota prispevkov T_{H_2O} in X_{new} ostane približno konstantna glede na osnovni model *v standardiziranem prostoru neposredno*, v *originalnem* prostoru pa šele ob upoštevanju faktorja 2 iz definicije X_{new} – pomembno opozorilo, da se tovrstna preverjanja pravilno izvajajo v prostoru, kjer imajo koeficienti neposreden fizikalen pomen.

Ključna ugotovitev:

Napaka modela (NRMSE) sama po sebi ne razkrije problema kolinearnosti – LSE in PCR dosežeta praktično enak NRMSE, a povsem različno stabilnost ocenjenih parametrov. Za zanesljivo identifikacijo modela pri (skoraj) kolinearnih vhodih je PCR bistveno boljša izbira, ker eksplicitno odstrani redundantno smer variance, preden izvede regresijo.